

Deep-Learning-basierte Anomalieerkennung in Passantenfrequenzen

Zeitabhängige Passantenfrequenzen enthalten komplexe Muster, die durch Tageszeiten, externe Einflüsse und Ereignisse geprägt sind. Ziel ist es, ungewöhnliche Abweichungen (Anomalien) automatisch zu erkennen. Grundlage bildet ein Datensatz der **Passantenfrequenzen der Stadt Bad Nauheim vom 30.06. bis 13.07.2025**.

Ziel des Projekts ist die Entwicklung und Evaluation eines **Deep-Learning-Systems zur Anomalieerkennung in Zeitreihendaten**. Dabei soll ein Modell das Normalverhalten der Passantenfrequenzen lernen und signifikante Abweichungen zuverlässig identifizieren.

Im Fokus steht nicht nur die Implementierung, sondern eine **methodisch saubere, quantitativ fundierte und optimierte Lösung**. Erwartet wird ein systematischer Vergleich mehrerer Deep-Learning-Ansätze mit klar nachvollziehbarer Leistungsbewertung.

Datenverarbeitung

- Fundierte explorative Analyse (Trends, Saisonalität, Ausreißer)
- Saubere Vorverarbeitung (Normalisierung, Glättung, Windowing)
- Begründete Wahl der Datenrepräsentation

Modellierung

- Implementierung und Vergleich von mindestens zwei Architekturen:
 - LSTM/GRU
 - Autoencoder (rekonstruktionsbasiert)
 - Transformer (erwartet für Bestleistung)
- Begründete Modellwahl und Architekturdesign

Training & Optimierung

- Geeignete Loss-Funktionen für Anomalieerkennung
- Systematische Hyperparameter-Optimierung
- Maßnahmen zur Trainingsstabilität (Regularisierung, Early Stopping)

Evaluation

Streng quantitative und reproduzierbare Bewertung mittels:

- **Konfusionsmatrix** (TP, FP, TN, FN)
- **Precision, Recall, F1-Score**
- **ROC-Kurve und AUC**
- **Koeffizient** zur Bewertung der Überlappung erkannter Anomalien

Vergleich der Modelle hinsichtlich:

- Erkennungsgenauigkeit
- Robustheit gegenüber Rauschen
- Generalisierungsfähigkeit

Analyse & Interpretation

- Nachvollziehbare Identifikation von Anomalien
- Kritische Interpretation der Ergebnisse
- Vergleich und Diskussion der Modellentscheidungen (keine Blackbox)

Implementierung

- Modularer, wartbarer und sauber strukturierter Code
- Reproduzierbare Experimente (inkl. Dokumentation der Parameter)

Erwartete Ergebnisse

- Leistungsfähiger Prototyp zur Anomalieerkennung
- Systematischer Vergleich mehrerer Deep-Learning-Modelle
- Quantitativ fundierte und nachvollziehbare Evaluation
- Aussagekräftige Visualisierung und Interpretation der Ergebnisse

Bewertungskriterien

- Methodisch sauberer und vollständiger Modellvergleich
- Einsatz und korrekte Interpretation fortgeschrittener Metriken
- Nachvollziehbare, reproduzierbare Experimente
- Tiefe technische und inhaltliche Analyse
- Keine Blackbox-Ansätze, sondern erklärbare Ergebnisse
- Wissenschaftlich präzise, strukturierte Ausarbeitung